

Βαθιά Μάθηση (Deep Learning)

(Διδάσκοντες: Νικόλαος Βασιλάς, Χρήστος Τρούσσας, Μαρία Κασελίμη)

Ακαδ.έτος: 2025-2026

Εργασία

Ταξινόμηση σπύλων του δέρματος (HAM10000)

Συγκριτική μελέτη MobileNetV2, EfficientNet-B0 και EfficientNetV2-S με σταδιακή αποδόμηση τεχνικών (ablation study)

Αποθετήριο github: <https://github.com/aivc25003/Skin-Cancer-Classification-AIVC>



Όνομα: Μιχαήλ Γάλλιας

Αρ. Μητρώου: aivc25003

1. Περιγραφή του θέματος

Ο καρκίνος του δέρματος είναι από τα συχνότερα είδη καρκίνου παγκοσμίως, με την έγκαιρη διάγνωση να είναι καθοριστική για την έκβαση του ασθενούς· στην περίπτωση του μελανώματος, το ποσοστό επιβίωσης πενταετίας ξεπερνά το 99% όταν η διάγνωση γίνεται σε πρώιμο στάδιο. Επειδή η διάγνωση βασίζεται σε οπτική επιθεώρηση και δερματοσκόπηση, και επειδή υπάρχει μεγάλη οπτική ομοιότητα μεταξύ καλοήθων και κακοήθων αλλοιώσεων, η αυτοματοποιημένη ταξινόμηση μέσω CNN αποτελεί ένα χρήσιμο υποστηρικτικό εργαλείο.

Η παρούσα εργασία πραγματεύεται την αυτοματοποιημένη ταξινόμηση δερματοσκοπικών εικόνων για τη διάγνωση του καρκίνου του δέρματος, με χρήση συνελκτικών νευρωνικών δικτύων (CNN) και τεχνικών βαθιάς μάθησης. Ως δεδομένα μάθησης χρησιμοποιήθηκε το dataset HAM10000, που περιλαμβάνει 10.015 δερματοσκοπικές εικόνες, κατανεμημένες σε επτά διαγνωστικές κλάσεις δερματικών αλλοιώσεων, με έντονη ανισορροπία μεταξύ τους.

Εξετάζονται και συγκρίνονται τρεις αρχιτεκτονικές βαθιάς μάθησης, με χρήση προεκπαιδευμένων μοντέλων μέσω transfer learning και fine-tuning, και ειδικότερα δοκιμάσθηκαν το MobileNetV2 ως ελαφρύ μοντέλο αναφοράς (baseline) και τα EfficientNet-B0 και EfficientNetV2-S ως δύο νεότερες, ισχυρότερες αρχιτεκτονικές. Για τα δύο τελευταία εφαρμόζεται σταδιακή ενεργοποίηση τεχνικών (weighted loss, επαύξηση δεδομένων, CutMix, scheduler) σε πέντε σενάρια, με στόχο την ανάδειξη της συνεισφοράς κάθε τεχνικής και ιδιαίτερη έμφαση στην ευαισθησία (Recall) εντοπισμού των σπάνιων αλλά κρίσιμων παθήσεων

2. Επισκόπηση βιβλιογραφίας

Το σύνολο δεδομένων HAM10000 των Tschandl, Rosendahl και Kittler (2018) αποτέλεσε σταθμό για το πεδίο, καθώς συγκέντρωσε 10.015 δερματοσκοπικές εικόνες από δύο διαφορετικούς πληθυσμούς (Αυστρία και Αυστραλία) σε επτά διαγνωστικές κλάσεις, με πάνω από το ήμισυ των αλλοιώσεων επιβεβαιωμένο

ιστοπαθολογικά. Πέρα από το μέγεθός του, το HAM10000 είναι σημαντικό, επειδή αποτυπώνει ρεαλιστικά την έντονη ανισορροπία των κλάσεων που συναντάται στην κλινική πράξη, ένα χαρακτηριστικό που καθορίζει σε μεγάλο βαθμό τις μεθοδολογικές επιλογές της παρούσας μελέτης.

Η δυνατότητα των συνελικτικών νευρωνικών δικτύων να προσεγγίσουν το επίπεδο των ειδικών τεκμηριώθηκε από τους Esteva et al. (2017), οι οποίοι έδειξαν ότι ένα δίκτυο Inception-v3, εκπαιδευμένο με transfer learning, μπορεί να ταξινομεί καρκίνους του δέρματος στο επίπεδο έμπειρων δερματολόγων. Στο ίδιο πνεύμα, οι Chaturvedi, Gupta και Prasad (2020) εφάρμοσαν ένα ελαφρύ δίκτυο MobileNet στο HAM10000 για ταξινόμηση επτά κλάσεων, αναδεικνύοντας ότι ακόμη και αρχιτεκτονικές χαμηλού υπολογιστικού κόστους μπορούν να αποδώσουν ικανοποιητικά μέσω μεταφοράς γνώσης από το ImageNet. Η εργασία αυτή χρησιμοποιείται εδώ ως σημείο αναφοράς (baseline).

Αναφορικά με τις σχετικές αρχιτεκτονικές μηχανικής μάθησης, οι Tan & Le (2019) εισήγαγαν την οικογένεια EfficientNet, η οποία στηρίζεται στην ιδέα του compound scaling, όπου, αντί να κλιμακώνεται μεμονωμένα το βάθος, το πλάτος ή η ανάλυση ενός δικτύου, αυτές οι τρεις διαστάσεις αυξάνονται ταυτόχρονα και ισορροπημένα, επιτυγχάνοντας υψηλότερη ακρίβεια με σημαντικά λιγότερες παραμέτρους. Το EfficientNet-B0 είναι το βασικό μοντέλο αυτής της οικογένειας. Λίγα χρόνια αργότερα, οι ίδιοι ερευνητές (Tan & Le, 2021) παρουσίασαν το EfficientNetV2, το οποίο βελτιώνει την προηγούμενη γενιά μέσω training-aware neural architecture search, των Fused-MBConv δομικών μπλοκ και της προοδευτικής μάθησης (progressive learning), προσφέροντας ταχύτερη εκπαίδευση και καλύτερη αξιοποίηση των παραμέτρων. Το EfficientNetV2-S είναι το πιο σύγχρονο μοντέλο που εξετάζεται στην εργασία.

Καθώς βασική δυσκολία του HAM10000 αποτελεί η ανισορροπία και η τάση των δικτύων προς υπερπροσαρμογή, επιχειρούνται επιπροσθέτως και αρκετές τεχνικές εξομάλυνσης. Οι Yun et al. (2019) πρότειναν το CutMix, μια στρατηγική επαύξησης δεδομένων (data augmentation), όπου τμήματα μιας εικόνας κόβονται και επικολλώνται σε μια άλλη, με τις ετικέτες να αναμειγνύονται αναλογικά προς το εμβαδόν του τμήματος. Σε αντίθεση με προγενέστερες τεχνικές, το CutMix δεν

καταστρέφει χρήσιμη πληροφορία και βελτιώνει τόσο τη γενίκευση όσο και την ανθεκτικότητα.

Επίσης, οι He & Garcia (2009) παρέχουν την πιο ολοκληρωμένη επισκόπηση των τεχνικών αντιμετώπισης της ανισορροπίας, κατατάσσοντας το cost-sensitive learning, στο οποίο ανήκει το weighted cross-entropy loss, που επιστρατεύεται στην παρούσα εργασία, ως μια από τις πιο αποτελεσματικές προσεγγίσεις. Σύμφωνα με την εν λόγω τεχνική, αντί να αντιμετωπίζονται όλες οι κλάσεις εξίσου κατά τον υπολογισμό του σφάλματος, κάθε κλάση λαμβάνει βάρος αντιστρόφως ανάλογο της συχνότητάς της, ώστε τα λάθη στις σπάνιες παθήσεις να τιμωρούνται αναλογικά βαρύτερα.

Τέλος, για τη βελτιστοποίηση, οι Loshchilov & Hutter (2019) έδειξαν ότι για προσαρμοστικούς αλγορίθμους όπως ο Adam το L2 regularization και το weight decay δεν είναι ισοδύναμα και πρότειναν τον AdamW με αποσυζευγμένο weight decay, σε συνδυασμό με προγραμματισμό του ρυθμού μάθησης βάσει cosine annealing, δύο τεχνικές που υιοθετήθηκαν ευθέως στα πειράματα που πραγματοποιήθηκαν.

3. Το Σύνολο Δεδομένων HAM10000

Όπως προειπώθηκε, το HAM10000 αποτελείται από 10.015 δερματοσκοπικές εικόνες ταξινομημένες σε επτά διαγνωστικές κλάσεις, συνοδευόμενες από αρχείο μεταδεδομένων (CSV) με την ετικέτα διάγνωσης (dx) κάθε εικόνας. Η αναλογία της μεγαλύτερης προς τη μικρότερη κλάση υπερβαίνει το 58:1.

Χαρακτηρίζεται από έντονη ανισορροπία, όπου η κλάση των μελανοκυτταρικών σπύλων (nv) κυριαρχεί απόλυτα, ενώ κλάσεις όπως το δερματοΐνωμα (df) και οι αγγειακές αλλοιώσεις (vasc) είναι εξαιρετικά σπάνιες.

Κατανομή των επτά κλάσεων του HAM10000 (Tschandl et al., 2018).

Κωδικός	Διαγνωστική Κλάση	Φύση	Εικόνες (σύνολο)
nv	Μελανοκυτταρικοί σπίλοι	Καλοήθης	6.705
mel	Μελάνωμα	Κακοήθης	1.113
bkl	Καλοήθης κεράτωση	Καλοήθης	1.099
bcc	Βασικοκυτταρικό καρκίνωμα	Κακοήθης	514
akiec	Ακτινική κεράτωση / Bowen	Προ-κακοήθης	327
vasc	Αγγειακές αλλοιώσεις	Καλοήθης	142
df	Δερματοΐνωμα	Καλοήθης	115

4. Μεθοδολογία

Το σύνολο δεδομένων χωρίστηκε σε 80% εκπαίδευση και 20% έλεγχο με σταθερό seed (42), ώστε ο διαχωρισμός να είναι ίδιος για όλα τα μοντέλα και τα αποτελέσματα συγκρίσιμα. Το σύνολο ελέγχου αποτελείται από 2.003 εικόνες. Όλες οι εικόνες σμικρύνθηκαν σε διαστάσεις (224×224 pixels) και κανονικοποιήθηκαν με τις μέσες τιμές και τυπικές αποκλίσεις του ImageNet, ενώ η εκπαίδευση έγινε για 15 εποχές με μέγεθος batch 32.

Η συνειδητή επιλογή της μη χρήσης κάποιας μεθόδου Cross-Validation οφείλεται στο υπερβολικό υπολογιστικό κόστος που θα συνεπαγόταν, δεδομένης της εφαρμογής πολλών εκδοχών κάθε μοντέλου (ablation study). Συγχρόνως, όμως, κρίνεται επιστημονικά απολύτως δόκιμη για δύο λόγους. Πρώτον, το μεγάλο μέγεθος του συνόλου δεδομένων (10.015 εικόνες) εξασφαλίζει επαρκή αντιπροσώπευση στο test set. Δεύτερον, η εκτενής χρήση μεταφερόμενης μάθησης (Transfer Learning) μέσω προεκπαιδευμένων βαρών (ImageNet) προσφέρει στο μοντέλο ισχυρή σταθερότητα και ικανότητα γενίκευσης από τα πρώτα κιόλας στάδια, μετριάζοντας σημαντικά τον κίνδυνο της υψηλής διακύμανσης (variance), η οποία συνήθως καθιστά το cross-

validation αναγκαίο σε μοντέλα που εκπαιδεύονται από το μηδέν.

Η επιλογή έγινε ώστε η σύγκριση να καλύπτει ένα ευρύ φάσμα, από το κλασικό ελαφρύ baseline μέχρι τη σύγχρονη state-of-the-art λογική:

- **MobileNetV2 (Baseline):** Ελαφριά αρχιτεκτονική για κινητές/ενσωματωμένες συσκευές. Αναπαράγει τη λογική του paper αναφοράς (MobileNet στο HAM10000) και θέτει το σημείο εκκίνησης ως προς το οποίο μετριέται κάθε βελτίωση.
- **EfficientNet-B0 (συγκρίσιμο μοντέλο):** Παρόμοιας τάξης μεγέθους με το MobileNetV2 ($\approx 5,3$ εκατ. έναντι $\approx 3,4$ εκατ. παραμέτρων), αλλά βασισμένο στο compound scaling. Επιτρέπει μια δίκαιη σύγκριση αρχιτεκτονικής στο ίδιο επίπεδο πόρων.
- **EfficientNetV2-S (state-of-the-art):** Μεγαλύτερο και πιο σύγχρονο δίκτυο (≈ 21 εκατ. παράμετροι) με Fused-MBConv blocks και βελτιωμένη εκπαίδευση. Αντιπροσωπεύει το άνω όριο απόδοσης και δείχνει τι κερδίζουμε αυξάνοντας τη χωρητικότητα του μοντέλου.

Και τα τρία μοντέλα φορτώθηκαν με προεκπαιδευμένα βάρη ImageNet ('DEFAULT'), και το τελικό γραμμικό επίπεδο (classifier) αντικαταστάθηκε ώστε να εξάγει 7 κλάσεις αντί για 1000 (transfer learning + fine-tuning).

Προδιαγραφές εκπαίδευσης των μοντέλων

Παράμετρος	MobileNetV2 (Baseline)	EfficientNet-B0 / V2-S
Optimizer	Adam	AdamW (weight_decay=0,01)
Learning rate	0,001 (σταθερό)	0,0001 (+ προαίρ. cosine)
Loss	CrossEntropy (απλό)	CrossEntropy ή Weighted
Augmentation	Μόνο Resize + Normalize	Flip/Rotation/Jitter + CutMix
Εποχές / Batch	15 / 32	15 / 32
Ανάλυση εικόνων	224×224 px	224×224 px

5. Τεχνικές και Μέθοδοι που Εφαρμόστηκαν

Στα δύο νέα μοντέλα εφαρμόστηκαν διαδοχικά τέσσερις τεχνικές, καθεμία ελεγχόμενη από έναν διακόπτη (flag). Η σταδιακή ενεργοποίησή τους (ablation study) αποσκοπεί στην απομόνωση και στην αξιολόγηση της συμβολής κάθε επιπρόσθετης τεχνικής στην απόδοση των μοντέλων.

5.1 Weighted Loss

Λόγω της προεκτεθείσας ανισορροπίας των κλάσεων, ένα δίκτυο στην απλή του μορφή τείνει να αγνοεί τις σπάνιες κλάσεις, μεγιστοποιώντας την ακρίβεια προβλέποντας σχεδόν πάντα την κυρίαρχη κλάση (nv). Για να αντιμετωπιστεί αυτή η συμπεριφορά, σε κάθε κλάση αποδίδεται βάρος αντιστρόφως ανάλογο της συχνότητάς της και επομένως, όσο σπανιότερη η πάθηση, τόσο μεγαλύτερη είναι και η τιμωρία για ένα λάθος σε αυτήν. Τα βάρη κανονικοποιήθηκαν, προκειμένου να διατηρηθεί η ίδια κλίμακα του loss με το απλό CrossEntropy, αποφεύγοντας αριθμητικά προβλήματα ή ανάγκη επαναρύθμισης του learning rate.

5.2 Basic Augmentation (Flips, Rotations, Color Jitter)

Η βασική επαύξηση (data augmentation) εφαρμόζει τυχαίους, ρεαλιστικούς μετασχηματισμούς μόνο στο σύνολο εκπαίδευσης (το test set μένει πάντα καθαρό για αντικειμενική αξιολόγηση). Οι επιμέρους τεχνικές που επιστρατεύθηκαν είναι οι ακόλουθες:

- **Random Horizontal Flip:** 50% πιθανότητα οριζόντιας αναστροφής της εικόνας, αφού μια αλλοίωση δέρματος δεν έχει σωστό και λάθος προσανατολισμό.
- **Random Rotation:** τυχαία περιστροφή $\pm 15^\circ$ (B0) ή $\pm 20^\circ$ (V2-S), προσομοιώνοντας διαφορετικές γωνίες λήψης του δερματοσκοπίου.
- **Color Jitter ($\pm 10\%$):** μεταβολή φωτεινότητας, αντίθεσης και κορεσμού, προσομοιώνοντας διαφορετικές συνθήκες φωτισμού και εξοπλισμού μεταξύ ιατρείων.

Συνολικά η τεχνική αυξάνει τεχνητά την ποικιλομορφία των δεδομένων και βελτιώνει

τη γενίκευση.

5.3 CutMix

Το CutMix (Yun et al., 2019) κόβει ένα ορθογώνιο τμήμα από μια εικόνα και το επικολλά πάνω σε άλλη, ενώ η ετικέτα-στόχος γίνεται μείξη των δύο κλάσεων αναλογικά προς το εμβαδόν του τμήματος. Σε αντίθεση με το Cutout (που μηδενίζει pixels) ή το Mixup (που υπερθέτει ολόκληρες εικόνες), το CutMix δεν χάνει χρήσιμη πληροφορία και παράγει πιο φυσικές εικόνες. Υλοποιήθηκε μέσω του torchvision.transforms.v2 με num_classes=7. Επιδρά στη διαδικασία μάθησης δυσκολεύοντας επίτηδες την εκπαίδευση, ρίχνοντας αισθητά το training accuracy (το δίκτυο καλείται να αναγνωρίσει δύο παθήσεις σε μία εικόνα), αλλά συγχρόνως καθιστώντας το μοντέλο πιο ανθεκτικό στο overfitting.

Στο σημείο αυτό, είναι απαραίτητες δύο διευκρινίσεις για τη σωστή ανάγνωση των σεναρίων με CutMix (4 και 5):

- Πρώτον, στα σενάρια αυτά το training accuracy που καταγράφεται είναι παραπλανητικά χαμηλό (ξεκινά γύρω στο 0,38–0,40). Αυτό συμβαίνει επειδή το δίκτυο εκπαιδεύεται σε αναμειγμένες εικόνες με μικτές ετικέτες, ενώ η ακρίβεια μετριέται ως προς την αρχική (μη μικτή) ετικέτα. Πρόκειται για τεχνητό αποτέλεσμα του τρόπου μέτρησης και όχι για ένδειξη ότι το δίκτυο δεν μαθαίνει. Αντιθέτως, η ίδια η μάθηση γίνεται σωστά, όπως επιβεβαιώνεται από το train loss που μειώνεται ομαλά και από τα έγκυρα test metrics (στο σύνολο ελέγχου δεν εφαρμόζεται CutMix). Συνεπώς, οι καμπύλες train accuracy των σεναρίων 4 και 5 δεν πρέπει να ερμηνεύονται ως πραγματική απόδοση.

- Δεύτερον, το ότι το CutMix δεν βελτίωσε πάντα τα αποτελέσματα δεν σημαίνει ότι είναι ακατάλληλη τεχνική, αλλά ότι εδώ εφαρμόστηκε σε δυσμενείς συνθήκες. Το CutMix, όπως και στο πρωτότυπο paper, αποδίδει πλήρως μόνο με μεγάλο αριθμό εποχών. Με μόλις 15 εποχές το δίκτυο δεν προλαβαίνει να επωφεληθεί από τη δυσκολία που εισάγει. Επιπλέον, ο συνδυασμός CutMix και weighted loss ασκεί ταυτόχρονα δύο ισχυρές πιέσεις, κάτι που υπερφορτώνει ένα μικρό δίκτυο όπως το EfficientNet-B0 (όπου τα σενάρια 4-5 μείωσαν το accuracy χωρίς όφελος στο Recall).

Αντίθετα, στο μεγαλύτερο EfficientNetV2-S, όπου υπάρχει περισσότερη χωρητικότητα και ο scheduler σταθεροποιεί τη σύγκλιση, το CutMix στο πλήρες σενάριο συνέβαλε στο υψηλότερο macro Recall (0,85). Συμπερασματικά, η χρησιμότητα του CutMix εξαρτάται από τη χωρητικότητα του δικτύου και τον διαθέσιμο χρόνο εκπαίδευσης.

5.4 AdamW και Cosine Annealing Scheduler

Αντί του απλού Adam του baseline, στα δύο νέα μοντέλα χρησιμοποιήθηκε ο AdamW (Loshchilov & Hutter, 2019), ο οποίος στηρίζεται στην αποσύζευξη του weight decay από το βήμα του gradient, περιορίζοντας την υπερβολική ανάπτυξη των βαρών και βελτιώνοντας τη γενίκευση. Στο πλήρες σενάριο προστέθηκε ο Cosine Annealing scheduler ($T_{max}=15$), όπου ο ρυθμός μάθησης μειώνεται ομαλά κατά καμπύλη συνημιτόνου, φτάνοντας σχεδόν στο μηδέν στην τελευταία εποχή, ώστε το δίκτυο να συγκλίνει ομαλά σε ένα ελάχιστο χωρίς απότομες αναπηδήσεις.

6. Αποτελέσματα

Οι Πίνακες Σύγχυσης και Καμπύλες Μάθησης, καθώς και τα πλήρη αριθμητικά αποτελέσματα παρατίθενται στα Παραρτήματα 1 και 2 αντίστοιχα τους παρόντος.

Όλες οι μετρικές προέρχονται από το σύνολο ελέγχου των 2.003 εικόνων. Δίνεται έμφαση στο Recall των δύο κρίσιμων και σπάνιων κλάσεων, ήτοι στο mel (μελάνωμα) και το df (δερματοϊνώμα), καθώς και στο macro-averaged ROC-AUC, που αποδίδει ίση βαρύτητα σε όλες τις κλάσεις ανεξαρτήτως συχνότητας.

6.1 MobileNetV2 (Baseline)

Μετρική	Τιμή
Accuracy (συνολικό)	0,84
Macro avg F1-score	0,73
Macro avg Recall	0,68
Recall - mel (μελάνωμα)	0,57
Recall - df (δερματοϊνωμα)	0,52
Macro avg ROC-AUC	0,96

Παρά την ικανοποιητική συνολική ακρίβεια (0,84), το χαμηλό macro Recall (0,68) αποκαλύπτει ότι το δίκτυο στην απλή του μορφή υστερεί στις σπάνιες κλάσεις.

6.2 EfficientNet-B0 (τα 5 σενάρια)

Σενάριο	Τεχνικές (W/A/C/S)	Test Acc	Macro avg F1-score	Macro avg Recall	Recall mel	Recall df	Macro avg ROC-AUC
1. Γυμνό	F / F / F / F	0,88	0,79	0,79	0,63	0,78	0,98
2. +Weighted	T / F / F / F	0,87	0,78	0,81	0,63	0,85	0,98
3. +Augment	T / T / F / F	0,83	0,75	0,82	0,74	0,89	0,98
4. +CutMix	T / T / T / F	0,78	0,68	0,80	0,63	0,85	0,97
5. +Scheduler	T / T / T / T	0,74	0,63	0,79	0,63	0,85	0,96

* W=Weighted Loss, A=Augmentation, C=CutMix, S=Scheduler.

Το απλό B0 ξεκινά ήδη πολύ ψηλά (0,88 accuracy), σαφώς πάνω από το baseline. Το weighted loss ανεβάζει το macro Recall (0,79 → 0,81) και ιδίως το df (0,78 → 0,85) με μικρό κόστος στην ακρίβεια. Η προσθήκη της βασικής επαύξεσης (σενάριο 3)

αποδίδει το καλύτερο προφίλ ευαισθησίας του μοντέλου, όπου το macro Recall κορυφώνεται στο 0,82 και το Recall του μελανώματος ανεβαίνει αισθητά (0,63 → 0,74). Από εκεί και πέρα, το CutMix και ο scheduler μειώνουν περαιτέρω το accuracy χωρίς αντίστοιχο όφελος στο Recall, υποδηλώνοντας ότι για ένα μικρότερο δίκτυο όπως το B0 ο συνδυασμός όλων των τεχνικών είναι υπερβολικά επιθετικός.

6.3 EfficientNetV2-S (5 σενάρια)

Σενάριο	Τεχνικές (W/A/C/S)	Test Acc	Macro avg F1-score	Macro avg Recall	Recall mel	Recall df	Macro avg ROC-AUC
1. Γυμνό	F / F / F / F	0,87	0,77	0,77	0,56	0,59	0,98
2. +Weighted	T / F / F / F	0,84	0,76	0,80	0,69	0,74	0,98
3. +Augment	T / T / F / F	0,85	0,80	0,83	0,75	0,81	0,97
4. +CutMix	T / T / T / F	0,77	0,64	0,78	0,71	1,00	0,93
5. +Scheduler	T / T / T / T	0,85	0,78	0,85	0,62	0,93	0,96

* W=Weighted Loss, A=Augmentation, C=CutMix, S=Scheduler.


Το V2-S στην απλή του μορφή, παρά το υψηλό accuracy (0,87), έχει χαμηλό macro Recall (0,77) και ιδιαίτερα φτωχό Recall στις σπάνιες κλάσεις (df 0,59, mel 0,56). Με τη σταδιακή ενεργοποίηση των τεχνικών, το macro Recall ανεβαίνει σταθερά (0,77 → 0,80 → 0,83) και το σενάριο 3 πετυχαίνει την καλύτερη ισορροπία ακρίβειας-ευαισθησίας με τα υψηλότερα ποσοστά εντοπισμού μελανώματος (mel 0,75). Το μεμονωμένο σενάριο 4 (CutMix χωρίς scheduler) εμφανίζει αστάθεια, καθώς εκτοξεύει το df στο 1,00, ενώ συγχρόνως καταρρέει σε precision και AUC. Το πλήρες μοντέλο (σενάριο 5) επαναφέρει την ισορροπία χάρη στον scheduler, πετυχαίνοντας το υψηλότερο macro Recall (0,85) με διατηρημένο accuracy (0,85) και υψηλό και το macro F1 (0,78), ενώ η ευαισθησία στις σπάνιες κλάσεις (df 0,93) παραμένει πολύ υψηλή. Αυτό δείχνει ότι το μεγαλύτερο δίκτυο αξιοποιεί καλύτερα τη ρυθμιστική επίδραση του CutMix, όταν σταθεροποιείται από τον scheduler.

7. Σύγκριση, Δυνατότητες και Περιορισμοί

Συγκριτική σύνοψη με βάση το καλύτερο σενάριο κάθε μοντέλου.

Μοντέλο (καλύτερο σενάριο)	Test Acc	Macro Recall	Macro F1	Macro ROC-AUC
MobileNetV2 (baseline)	0,84	0,68	0,73	0,9574
EfficientNet-B0 (σενάριο 3)	0,83	0,82	0,75	0,9733
EfficientNetV2-S (σενάριο 5)	0,85	0,85	0,78	0,9601

Σύγκριση Test Accuracy, Macro Recall και Macro ROC-AUC για την καλύτερη εκδοχή κάθε μοντέλου.



Από τη γενικότερη σύγκριση των αποτελεσμάτων διενεργηθέντων πειραμάτων προκύπτουν τα εξής συμπεράσματα:

- **Αρχιτεκτονική vs. baseline:** Και τα δύο EfficientNet ξεπερνούν ξεκάθαρα το MobileNetV2 σε macro Recall (0,82 και 0,85 έναντι 0,68), επιβεβαιώνοντας ότι το compound scaling και οι νεότερες τεχνικές προσφέρουν πραγματικό όφελος στο ίδιο ή ελαφρώς υψηλότερο υπολογιστικό κόστος.
- **Accuracy vs. Recall trade-off:** Η εμμονή στο συνολικό accuracy είναι


παραπλανητική σε ανισόρροπα ιατρικά δεδομένα. Οι τεχνικές που κοστίζουν σε accuracy (weighted loss, CutMix) βελτιώνουν συστηματικά την ευαισθησία στις σπάνιες αλλά κλινικά κρίσιμες κλάσεις.

- **Ρόλος της χωρητικότητας:** Στο μικρότερο B0 η σώρευση όλων των τεχνικών (σενάρια 4-5) μειώνει το accuracy χωρίς όφελος στο Recall, με την ισορροπία να επιτυγχάνεται νωρίτερα στο σενάριο 3. Αντίθετα, το μεγαλύτερο V2-S απορροφά καλύτερα τη δυσκολία του CutMix και αποδίδει βέλτιστα στο πλήρες σενάριο.
- **Περιορισμοί:** Στα πιο επιθετικά σενάρια εμφανίζεται πολύ χαμηλό precision στις σπάνιες κλάσεις (π.χ. vasc στο B0, df στο V2-S σενάριο 4), δηλαδή πολλά false positives, που συνιστά ένδειξη υπερ-πρόβλεψης των σπάνιων κλάσεων. Επιπλέον, το HAM10000 περιέχει πολλαπλές φωτογραφίες της ίδιας δερματικής αλλοίωσης, δηλαδή η ίδια αλλοίωση φωτογραφήθηκε από ελαφρώς διαφορετικές γωνίες, φωτισμούς ή μεγεθύνσεις. Αυτές οι πολλαπλές λήψεις αντιστοιχούν σε διαφορετικές εικόνες, αλλά στο ίδιο περιστατικό στο CSV. Αυτό σημαίνει ότι εικόνες της ίδιας αλλοίωσης μπορεί να βρεθούν και στο train και στο test set ταυτόχρονα. Έτσι, ο διαχωρισμός train/test ανά εικόνα και όχι ανά αλλοίωση ενδέχεται να υπερεκτιμά την απόδοση.

8. Ανάλυση Σφαλμάτων ανά Κλάση


Πέρα από τις συνολικές μετρικές, οι πίνακες σύγχυσης (confusion matrices) αποκαλύπτουν πού ακριβώς συγκεντρώνονται τα σφάλματα και ποιες κλάσεις συγχέονται μεταξύ τους. Η ανάλυση που ακολουθεί βασίζεται στους πίνακες σύγχυσης του test set (2.003 εικόνες), για την καλύτερη εκδοχή κάθε μοντέλου, ήτοι το απλό MobileNetV2, το EfficientNet-B0 στο σενάριο 3 και το EfficientNetV2-S στο σενάριο 5.

MobileNetV2 (baseline)




Το σοβαρότερο σφάλμα καθίσταται σαφές. Από τα 228 πραγματικά μελανώματα, τα 81 ταξινομήθηκαν λανθασμένα ως καλοήθεις σπίλοι (mel $\rightarrow$ nv), δηλαδή το πιο επικίνδυνο είδος λάθους (ένα κακόηθες περιστατικό εκλαμβάνεται ως αθώο). Παράλληλα, η καλοήθης κεράτωση μπερδεύεται έντονα προς δύο κατευθύνσεις, 39 περιπτώσεις bkl $\rightarrow$ nv και 30 bkl $\rightarrow$ mel. Αντίστροφα, 36 σπίλοι προβλέφθηκαν ως μελανώματα (nv $\rightarrow$ mel). Η εικόνα επιβεβαιώνει ότι το βασικό μπέρδεμα είναι η τριάδα mel-nv-bkl, με τη nv (την κυρίαρχη κλάση) να απορροφά λανθασμένα τις γειτονικές της κατηγορίες.

EfficientNet-B0 (σενάριο 3)



Η επίδραση του weighted loss και του data augmentation είναι ορατή στον πίνακα. Συγκεκριμένα, τα κρίσιμα σφάλματα $mel \rightarrow nv$ πέφτουν από 81 (baseline) σε μόλις 34, δηλαδή το δίκτυο χάνει πολύ λιγότερα μελανώματα. Το τίμημα βέβαια εμφανίζεται στην αντίθετη κατεύθυνση, αφού τώρα 95 σπίλοι ταξινομούνται ως μελανώματα ($nv \rightarrow mel$) και 43 ως καλοήθης κεράτωση ($nv \rightarrow bkl$). Με άλλα λόγια, το μοντέλο έγινε πιο καχύποπτο και προτιμά να σημάνει συναγερμό παρά να χάσει ένα μελάνωμα, κάτι που σε ιατρικό πλαίσιο είναι το επιθυμητό. Εμφανίζεται επίσης σύγχυση 26 περιπτώσεων $bkl \rightarrow akiec$, δύο κατηγοριών που όντως μοιάζουν μορφολογικά.

EfficientNetV2-S (σενάριο 5)



Το πιο σύγχρονο μοντέλο πετυχαίνει την καλύτερη ισορροπία. Τα σφάλματα $mel \rightarrow nv$ (51) και $nv \rightarrow mel$ (55) είναι πλέον σχεδόν συμμετρικά, ένδειξη ότι το δίκτυο δεν κλίνει υπερβολικά προς καμία κατεύθυνση. Η διαγώνιος είναι πιο πυκνή σε όλες τις κλάσεις (π.χ. 165 σωστά bkl, 62 σωστά akiec) και οι σπάνιες κλάσεις df και vasc αναγνωρίζονται σχεδόν στο σύνολό τους (25/27 και 27/27). Παραμένει η σύγχυση 43 σπύλων προς bkl ($nv \rightarrow bkl$) και μερικά μελανώματα που χάνονται προς nv, αλλά συνολικά η κατανομή των σφαλμάτων είναι πιο ομαλή από τα άλλα δύο μοντέλα.

Συμπέρασμα

Και στα τρία μοντέλα ο βασικός πυρήνας δυσκολίας τυγχάνει η ίδια τριάδα κλάσεων, ήτοι το μελάνωμα (mel), οι σπύλοι (nv) και η καλοήθης κεράτωση (bkl), τρεις κατηγορίες με μεγάλη οπτική ομοιότητα. Η κρίσιμη μετάβαση από το baseline στα EfficientNet συνίσταται στη δραστική μείωση των επικίνδυνων σφαλμάτων $mel \rightarrow nv$ (από 81 σε 34-51), με αντίτιμο όμως περισσότερους ψευδείς συναγερμούς ($nv \rightarrow mel$), ένα trade-off περισσότερο επιθυμητό στην ιατρική διάγνωση, όπου η μη ανίχνευση ενός μελανώματος είναι ασύγκριτα πιο επικίνδυνη από έναν περιττό

επανέλεγχο. Οι σπάνιες κλάσεις (df, vasc) αναγνωρίζονται σχεδόν πλήρως στα νεότερα μοντέλα, αν και με κάποιες λανθασμένες θετικές προβλέψεις. Η αξιόπιστη διάκριση του μελανώματος από τους καλοήθεις σπύλους παραμένει η κεντρική ανοιχτή πρόκληση.

9. Τελικά Συμπεράσματα

Η μελέτη έδειξε ότι η μετάβαση από το ελαφρύ MobileNetV2 σε σύγχρονες αρχιτεκτονικές EfficientNet, σε συνδυασμό με στοχευμένες τεχνικές για την ανισορροπία και τη γενίκευση, βελτιώνει ουσιαστικά την ικανότητα του μοντέλου να εντοπίζει τις σπάνιες αλλά επικίνδυνες παθήσεις. Το EfficientNetV2-S στο πλήρες σενάριο πέτυχε την καλύτερη συνολική ισορροπία (accuracy 0,85, macro Recall 0,85), ενώ το EfficientNet-B0 έδωσε το καλύτερο προφίλ του ήδη στο σενάριο 3, υποδεικνύοντας ότι ο βέλτιστος συνδυασμός τεχνικών εξαρτάται από τη χωρητικότητα του δικτύου. Το Ablation Study επιβεβαίωσε ότι κάθε τεχνική προσφέρει διακριτό όφελος: το weighted loss και η επαύξηση ενισχύουν την ευαισθησία στις σπάνιες κλάσεις, το CutMix αυξάνει την ανθεκτικότητα και ο AdamW με cosine annealing σταθεροποιεί την τελική σύγκλιση. Σε ιατρικό πλαίσιο, όπου το κόστος ενός false negative είναι υψηλό, η βελτίωση του Recall δικαιολογεί πλήρως τη μικρή θυσία σε συνολική ακρίβεια.


Βιβλιογραφία

- Chaturvedi, S. S., Gupta, K., & Prasad, P. S. (2020). Skin lesion analyser: An efficient seven-way multi-class skin cancer classification using MobileNet. In A. E. Hassanien, R. Bhatnagar, & A. Darwish (Eds.), *Advanced machine learning technologies and applications* (Advances in Intelligent Systems and Computing, Vol. 1141, pp. 165–176). Springer. https://doi.org/10.1007/978-981-15-3383-9_15
- Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. <https://doi.org/10.1038/nature21056>
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2009.74>
- Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *Proceedings of the 7th International Conference on Learning Representations (ICLR 2019)*. <https://arxiv.org/abs/1711.05101>
- Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, PMLR 97, 6105–6114. <https://arxiv.org/abs/1905.11946>
- Tan, M., & Le, Q. V. (2021). EfficientNetV2: Smaller models and faster training. *Proceedings of the 38th International Conference on Machine Learning (ICML 2021)*, PMLR 139, 10096–10106. <https://arxiv.org/abs/2104.00298>
- Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, Article 180161. <https://doi.org/10.1038/sdata.2018.161>
- Yun, S., Han, D., Oh, S. J., Chun, S., Choe, J., & Yoo, Y. (2019). CutMix: Regularization strategy to train strong classifiers with localizable features. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV 2019)*, 6023–6032. <https://doi.org/10.1109/ICCV.2019.00612>

ΠΑΡΑΡΤΗΜΑ 1: Πίνακες Σύγχυσης και Καμπύλες Μάθησης


Στο παράρτημα παρατίθενται, με τη σειρά εξέτασης, για κάθε μοντέλο και σενάριο ο πίνακας σύγχυσης (confusion matrix) και οι καμπύλες σφάλματος (loss) και ακρίβειας (accuracy) ανά εποχή. Οι συντομογραφίες στις παρενθέσεις δηλώνουν την κατάσταση των τεσσάρων flags τεχνικών με τη σειρά: W = Weighted Loss, A = Basic Augmentation, C = CutMix, S = Scheduler (T = ενεργό, F = ανενεργό).

A. MobileNetV2 (baseline) (χωρίς επιπλέον τεχνικές)




B. EfficientNet-B0 - 5 Σενάρια


Σενάριο 1 - Απλό (W:F A:F C:F S:F)




Σενάριο 2 - +Weighted Loss (W:T A:F C:F S:F)




Σενάριο 3 - +Augmentation (W:T A:T C:F S:F)



Σενάριο 4 - +CutMix (W:T A:T C:T S:F)




Σενάριο 5 - +Scheduler (πλήρες) (W:T A:T C:T S:T)




Γ. EfficientNetV2-S - 5 Σενάρια


Σενάριο 1 - Απλό (W:F A:F C:F S:F)




Σενάριο 2 - +Weighted Loss (W:T A:F C:F S:F)




Σενάριο 3 - +Augmentation (W:T A:T C:F S:F)



Σενάριο 4 - +CutMix (W:T A:T C:T S:F)



Σενάριο 5 - +Scheduler (πλήρες) (W:T A:T C:T S:T)



ΠΑΡΑΡΤΗΜΑ 2: Αριθμητικά αποτελέσματα

* Οι συντομογραφίες των flags δηλώνουν τις ενεργές τεχνικές: W = Weighted Loss, A = Basic Augmentation, C = CutMix, S = Scheduler (T = ενεργό, F = ανενεργό).

A. MobileNetV2 — Baseline

MobileNetV2 (baseline) (χωρίς επιπλέον τεχνικές)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,67	0,56	0,61	75	0,9694
bcc - Βασικοκυτταρικό καρκ.	0,78	0,70	0,73	105	0,9808
bkl - Καλοήθης κεράτωση	0,73	0,61	0,66	202	0,9617
df - Δερματοϊνωμα	0,93	0,52	0,67	27	0,9400
mel - Μελάνωμα	0,60	0,57	0,58	228	0,9012
nv - Μελανοκυτταρικοί σπύλοι	0,90	0,95	0,92	1339	0,9546
vasc - Αγγειακές αλλοιώσεις	0,96	0,89	0,92	27	0,9939
Accuracy (συνολικό)			0,84	2003	
Macro avg	0,79	0,68	0,73	2003	0,9574
Weighted avg	0,83	0,84	0,83	2003	

B. EfficientNet-B0

Σενάριο 1 — Γυμνό (W:F A:F C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,67	0,71	0,69	75	0,9809
bcc - Βασικοκυτταρικό καρκ.	0,78	0,79	0,79	105	0,9889
bkl - Καλοήθης κεράτωση	0,81	0,72	0,76	202	0,9652
df - Δερματοϊνωμα	0,81	0,78	0,79	27	0,9909
mel - Μελάνωμα	0,73	0,63	0,68	228	0,9324
nv - Μελανοκυτταρικοί σπύλοι	0,93	0,96	0,94	1339	0,9661
vasc - Αγγειακές αλλοιώσεις	0,87	0,96	0,91	27	0,9994
Accuracy (συνολικό)			0,88	2003	
Macro avg	0,80	0,79	0,79	2003	0,9748
Weighted avg	0,87	0,88	0,87	2003	

Σενάριο 2 — +Weighted Loss (W:T A:F C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,59	0,75	0,66	75	0,9797
bcc - Βασικοκυτταρικό καρκ.	0,75	0,78	0,76	105	0,9770
bkl - Καλοήθης κεράτωση	0,75	0,75	0,75	202	0,9636
df - Δερματοΐνωμα	0,82	0,85	0,84	27	0,9907
mel - Μελάνωμα	0,71	0,63	0,67	228	0,9411
nv - Μελανοκυτταρικοί σπύλοι	0,94	0,93	0,94	1339	0,9671
vasc - Αγγειακές αλλοιώσεις	0,81	0,96	0,88	27	0,9997
Accuracy (συνολικό)			0,87	2003	0,9741
Macro avg	0,77	0,81	0,78	2003	
Weighted avg	0,87	0,87	0,87	2003	

Σενάριο 3 — +Augmentation (W:T A:T C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,57	0,72	0,64	75	0,9653
bcc - Βασικοκυτταρικό καρκ.	0,72	0,90	0,80	105	0,9877
bkl - Καλοήθης κεράτωση	0,68	0,71	0,69	202	0,9500
df - Δερματοΐνωμα	0,69	0,89	0,77	27	0,9968
mel - Μελάνωμα	0,59	0,74	0,65	228	0,9466
nv - Μελανοκυτταρικοί σπύλοι	0,96	0,87	0,91	1339	0,9679
vasc - Αγγειακές αλλοιώσεις	0,68	0,93	0,78	27	0,9991
Accuracy (συνολικό)			0,83	2003	0,9733
Macro avg	0,70	0,82	0,75	2003	
Weighted avg	0,85	0,83	0,84	2003	

Σενάριο 4 — +CutMix (W:T A:T C:T S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,63	0,72	0,67	75	0,9563
bcc - Βασικοκυτταρικό καρκ.	0,56	0,90	0,69	105	0,9839
bkl - Καλοήθης κεράτωση	0,62	0,72	0,67	202	0,9499
df - Δερματοΐνωμα	0,79	0,85	0,82	27	0,9945
mel - Μελάνωμα	0,51	0,63	0,57	228	0,9187
nv - Μελανοκυτταρικοί σπύλοι	0,96	0,80	0,87	1339	0,9528
vasc - Αγγειακές αλλοιώσεις	0,32	1,00	0,49	27	0,9992
Accuracy (συνολικό)			0,78	2003	0,9650
Macro avg	0,63	0,80	0,68	2003	
Weighted avg	0,83	0,78	0,79	2003	

Σενάριο 5 — +Scheduler (πλήρες) (W:T A:T C:T S:T)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,54	0,77	0,64	75	0,9693
bcc - Βασικοκυτταρικό καρκ.	0,53	0,89	0,66	105	0,9772
bkl - Καλοήθης κεράτωση	0,58	0,67	0,62	202	0,9358
df - Δερματοΐνωμα	0,50	0,85	0,63	27	0,9800
mel - Μελάνωμα	0,46	0,63	0,53	228	0,9011
nv - Μελανοκυτταρικοί σπύλοι	0,96	0,75	0,85	1339	0,9480
vasc - Αγγειακές αλλοιώσεις	0,31	1,00	0,47	27	0,9982
Accuracy (συνολικό)			0,74	2003	0,9585
Macro avg	0,56	0,79	0,63	2003	
Weighted avg	0,82	0,74	0,76	2003	

Γ. EfficientNetV2-S

Σενάριο 1 — Γυμνό (W:F A:F C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,71	0,69	0,70	75	0,9784
bcc - Βασικοκυτταρικό καρκ.	0,81	0,83	0,82	105	0,9889
bkl - Καλοήθης κεράτωση	0,73	0,76	0,74	202	0,9609
df - Δερματοϊνωμα	0,89	0,59	0,71	27	0,9840
mel - Μελάνωμα	0,78	0,56	0,65	228	0,9253
nv - Μελανοκυτταρικοί σπίλοι	0,92	0,96	0,94	1339	0,9709
vasc - Αγγειακές αλλοιώσεις	0,76	0,96	0,85	27	0,9996
Accuracy (συνολικό)			0,87	2003	
Macro avg	0,80	0,77	0,77	2003	0,9726
Weighted avg	0,87	0,87	0,87	2003	

Σενάριο 2 — +Weighted Loss (W:T A:F C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,78	0,69	0,73	75	0,9698
bcc - Βασικοκυτταρικό καρκ.	0,75	0,83	0,79	105	0,9843
bkl - Καλοήθης κεράτωση	0,72	0,79	0,75	202	0,9658
df - Δερματοϊνωμα	0,57	0,74	0,65	27	0,9901
mel - Μελάνωμα	0,58	0,69	0,63	228	0,9225
nv - Μελανοκυτταρικοί σπίλοι	0,95	0,89	0,92	1339	0,9609
vasc - Αγγειακές αλλοιώσεις	0,71	1,00	0,83	27	0,9996
Accuracy (συνολικό)			0,84	2003	
Macro avg	0,72	0,80	0,76	2003	0,9704
Weighted avg	0,86	0,84	0,85	2003	

Σενάριο 3 — +Augmentation (W:T A:T C:F S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,74	0,75	0,74	75	0,9729
bcc - Βασικοκυτταρικό καρκ.	0,77	0,88	0,82	105	0,9782
bkl - Καλοήθης κεράτωση	0,68	0,76	0,72	202	0,9637
df - Δερματοΐνωμα	0,81	0,81	0,81	27	0,9710
mel - Μελάνωμα	0,61	0,75	0,67	228	0,9282
nv - Μελανοκυτταρικοί σπύλοι	0,95	0,89	0,92	1339	0,9650
vasc - Αγγειακές αλλοιώσεις	0,90	1,00	0,95	27	1,0000
Accuracy (συνολικό)			0,85	2003	0,9684
Macro avg	0,78	0,83	0,80	2003	
Weighted avg	0,87	0,85	0,86	2003	

Σενάριο 4 — +CutMix (W:T A:T C:T S:F)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,57	0,60	0,58	75	0,8766
bcc - Βασικοκυτταρικό καρκ.	0,75	0,63	0,68	105	0,8765
bkl - Καλοήθης κεράτωση	0,65	0,76	0,70	202	0,9369
df - Δερματοΐνωμα	0,20	1,00	0,34	27	0,9961
mel - Μελάνωμα	0,52	0,71	0,60	228	0,9011
nv - Μελανοκυτταρικοί σπύλοι	0,96	0,80	0,87	1339	0,9532
vasc - Αγγειακές αλλοιώσεις	0,57	0,96	0,71	27	0,9986
Accuracy (συνολικό)			0,77	2003	0,9341
Macro avg	0,60	0,78	0,64	2003	
Weighted avg	0,84	0,77	0,80	2003	

Σενάριο 5 — +Scheduler (πλήρες) (W:T A:T C:T S:T)

Κλάση	Precision	Recall	F1-score	Support	ROC-AUC
akiec - Ακτινική κεράτωση	0,78	0,83	0,80	75	0,9478
bcc - Βασικοκυτταρικό καρκ.	0,70	0,89	0,78	105	0,9649
bkl - Καλοήθης κεράτωση	0,71	0,82	0,76	202	0,9539
df - Δερματοΐνωμα	0,74	0,93	0,82	27	0,9709
mel - Μελάνωμα	0,66	0,62	0,64	228	0,9204
nv - Μελανοκυτταρικοί σπύλοι	0,95	0,89	0,92	1339	0,9626
vasc - Αγγειακές αλλοιώσεις	0,55	1,00	0,71	27	0,9998
Accuracy (συνολικό)			0,85	2003	
Macro avg	0,73	0,85	0,78	2003	0,9601
Weighted avg	0,86	0,85	0,86	2003	